

현재 진행 보고와 멘토에게 묻고 싶은 것

2026년 7월 29일 멘토링에서 SafeRoute의 현재 수준을 정확히 공유하고, 8월 14일 최종 발표와 이후 실제 파일럿을 위해 필요한 기술·제품·사업 판단을 받기 위한 브리프입니다.

승인 목표	PAID PILOT READY WITH SYNTHETIC OPERATIONS
현재 판정	HUMAN VALIDATION REQUIRED
기술 상태	자동·서비스 Gate 10/11 통과
오늘 목적	우선순위·A.X 활용·파일럿 설계·발표 메시지 결정

오늘 받고 싶은 결론

SafeRoute의 안전 코어와 AI 책임 분리가 올바른지, A.X 문서 추출 실험을 어떻게 다음 단계로 가져갈지, 첫 실제 파일럿을 어떤 데이터·규모·지표로 설계할지, 그리고 최종 발표에서 무엇을 가장 강하게 보여줄지 결정하고 싶습니다.

01 1분 진행 보고

멘토링 시작 시 이 페이지의 순서로 설명하면 됩니다.

25명 합성 운영 기사 전원 동일 평가시각	15건 지원 decision 복수 기사 동시 지원	299/299 단위·계약 최신 Gate 통과	33/33 브라우저 E2E 페루프 포함
--------------------------------------	--	---------------------------------------	------------------------------------

① 무엇을 만들었나

최신 합성 근무표·배송 작업표·경로표를 넣으면 전 기사를 평가하고, 지원이 필요한 각 기사에 대해 원인·개입안·동의·승인·경로·ETA·고객안내 초안·감사기록까지 처리하는 운영 서비스를 만들었습니다.

② 무엇이 다른가

AI가 위험점수나 추천을 결정하지 않습니다. Safety Budget·Time-to-Breach·Risk Transfer Guard는 결정론 코드가 소유하고, AI는 검증된 문서의 파싱과 역할별 근거 설명만 담당합니다.

③ 어디까지 검증했나

25명 운영일, 24·96·240명 부하, 불안전 추천 0건, D1 복구, 오래된 쓰기 409 차단, Upstage 문서·설명 Live, Kakao 경로 미리보기와 4개 지정 해상도를 검증했습니다.

④ 무엇이 남았나

현재 공식 blocker는 독립 사용자 검토 8명입니다. 이후 실제 상용 운영에는 인증·테넌트·실제 TMS/GPS·개인정보·운영 인프라·현장 Shadow pilot이 추가로 필요합니다.

멘토에게 바로 연결할 한 문장

“안전한 페루프와 합성 운영 서비스는 만들었습니다. 이제 AI의 제품 기여를 어디까지 확장해야 하는지, 실제 파일럿의 최소 데이터와 성공 지표가 무엇인지, 8월 14일 발표에서 무엇을 버리고 집중할지 조언을 받고 싶습니다.”

02 제품 정의와 구현된 페루프

SafeRoute는 사고확률 모델이 아니라 배송계획 변경 전 안전 가능성을 검증하는 운영 코파일럿입니다.

단계	기능	현재 구현
1	운영 입력	합성 문서 100개·25개 상위 레코드의 출처·날짜·참조·PII·누락 검증
2	전체 평가	모든 활성 기사를 같은 시각에서 Safety Budget·TTB·기여요인·신뢰도로 계산
3	개입 비교	휴식·물량이관·순서변경·안전경로·Safe Delay의 반사실적 효과 비교
4	위험전가 차단	수신 기사와 다른 열린 decision까지 재검증하여 새로운 breach 후보 차단
5	기사 권리	같은 decision ID에서 동의·수정 요청·거절을 별도 기사 화면으로 기록
6	관리자 승인	최신 스냅샷·계획 버전·동의 상태를 확인해 승인·보류·수정 요청
7	원자 적용	경로·배송순서·작업량·ETA를 함께 갱신하고 실패하면 기존 계획 유지
8	결과·감사	미발송 고객안내 초안, CSV/JSON 내보내기, 전후 지표와 감사 이벤트

설계에서 절대 약화하지 않은 것

Safety hard constraint

안전하지 않은 후보는 ETA·비용 비교 전에 제외합니다.

Risk Transfer Guard

한 기사의 위험을 다른 기사에게 넘기지 않습니다.

Two-key consent


기사 동의와 관리자 승인 뒤에만 적용합니다.

실제 데이터 경계

현재 기사·고객·위치·배송자료는 모두 합성입니다. 실제 정밀 GPS, 생체정보, 비공개 TMS, 실제 인증, 고객 메시지 발송, 사고감소 효과는 구현 완료로 주장하지 않습니다.

03 현재 서비스 화면과 주요 기능

관리자 5개 탭과 기사 3개 탭이 같은 workspace:snapshot-decision ID를 공유합니다.



관리자 · 개입 검토



기사 · 안전지원

영역	구성	현재 동작
관리자	운영 · 지원 · 경로 · 검토 · 감사	문서 입력, 기사 진행 지도, 적용 전후 경로, 개입 승인, 감사내보내기
기사	운영 · 안전지원 · 내 정보	Safe-until, 다음 배송·휴식, 동의·수정·거절, 데이터 공유 경계
지도	Kakao + schematic Fallback	25명 합성 진행 표시, 적용 경로 미리보기, 실제 GPS·자동 이동 아님
AI	문서·근거 설명	Upstage Parse-Extract와 역할별 설명, 수치·추천·실행 가능성 변경 금지
저장	D1 운영 workspace	새로고침·재접속 복구, 낙관적 동시성, 오래된 저장 409 차단

최근 디자인 반영

- #00BFFF·흰색 전역 헤더, 운영·지원·경로·검토·감사 사이드 레일
- ‘운영 문서 첨부’, ‘AI 근거 설명 생성’처럼 역할 중심 용어와 한 줄 버튼 배치
- 경로 탭에서 적용 전 계획과 승인된 활성 계획의 배송순서·ETA·지도 비교
- 지원 지도에서 25명 가명 기사와 완료/전체 배송 진행률 표시

04 시스템 설계와 AI 책임 경계

안전 결정은 코드가 소유하고 외부 AI-지도는 검증된 사실의 파싱·설명·표시에 제한됩니다.

계층	책임	가드레일
Domain	계약·Safety·개입·상태기계	순수 결정론, 외부 API 비의존
Application	스냅샷·fleet 평가·decision·적용·내보내기	유스케이스와 원자적 갱신
Adapters	Fixtures·Upstage·Kakao·기상·교통	경계 검증 후 내부 모델 변환
UI / PWA	관리자 5탭·기사 3탭·오프라인 읽기	동일 decision ID의 역할별 표현
Server	D1·Kakao proxy·Upstage proxy	비밀키·영속성·동시성 경계
Evaluation	Vitest·Playwright·부하·사람 Gate	완료 주장을 증거 파일·SHA에 연결

누가 무엇을 결정하는가

주체	허용 역할	권한 경계
SafeRoute 결정론 코드	Safety Budget, TTB, 신뢰도, 후보 효과·실행 가능성·추천·적용 상태	결정 권위
Upstage	합성 문서 Parse-Extract, 검증된 사실 기반 역할별 설명	새 수치·추천 금지
AX	문서 정보추출 연구 기준선, 관리자 요약·메모 후보	현재 런타임 미통합
Kakao	합성 좌표 지도·자동차 경로 미리보기	Safety 입력 금지
사람	기사 동의·수정·거절, 관리자 승인·보류	AI보다 우선

멘토에게 확인할 핵심 관점

- 이 책임 분리가 기업 고객과 대회 심사에서 'AI 활용이 약하다'가 아니라 '책임 있는 AI 설계'로 받아들여질 수 있는가?
- AI를 더 핵심적으로 보이게 하면서도 Safety·추천 권위를 넘기지 않을 가장 가치 있는 역할은 무엇인가?

05 검증 결과와 현재 판정

숫자는 2026-07-28 최신 서비스 Goal 감사와 공개 배포 smoke를 기준으로 합니다.

299 단위-계약 전부 통과	33 Playwright E2E 전부 통과	240명 최대 부하 13.7초 / 40초 예산	0건 불안전 추천 모든 부하에서 0
------------------------------	--------------------------------------	--	----------------------------------

기사	배송지	지원 결정	전체 준비시간	판정
24명	276건	14건	1.31초	통과
96명	1086건	56건	4.65초	통과
240명	2725건	143건	13.71초	통과

영역	결과
운영 증거	기사 25명 · 배송 284건 · 지원 15건
안전-충돌	불안전 추천 0건 · 충돌 시나리오 105건
D1	저장 200 · 재조회 200 · stale 쓰기 409
외부 연동	Upstage 설명 Live=true · Kakao Directions Live 통과
공식 상태	HUMAN_VALIDATION_REQUIRED · 관리자 0/3 · 기사 0/5

8월 14일 승인 목표

기획 추정 88~92% · 사람 Gate 0/8이 공식 blocker

실제 상용 운영

기획 추정 55~65% · 인증-실데이터-범무-운영-현장 검증 필요

릴리스 정합성 메모

현재 로컬 최신 커밋은 1f4b1b2이고 마지막 공개 배포 smoke 증거는 3de0fc4에 결속돼 있습니다. 디자인을 확정한 뒤 최신 상태를 재배포하고 D1-Upstage-사람 검토 manifest를 다시 고정해야 합니다.

06 A.X A100 문서 추출 실험

SKT 멘토에게 가장 구체적인 기술 조언을 받고 싶은 부분입니다.

분할	버전	통과	통과율	unsafe 표시
development	v1.0	0/60	0.0%	0
development	v1.1	28/60	46.7%	0
development	v1.2	33/60	55.0%	0
development	v1.3	35/60	58.3%	0
validation	v1.4	15/20	75.0%	0
frozen-test	v1.4	17/20	85.0%	0

무엇을 평가했나

배송 작업표·근무표·경로표·안전보고서 100건을 60/20/20으로 분리하고 strict JSON·표시값·원문 한 줄 인용·비신뢰 지시 Gate를 검증했습니다.

왜 제품에 넣지 않았나

frozen 17/20이지만 비신뢰 안전보고서 1건의 citation exact contract가 실패했습니다. 사전 기준에 따라 PARTIAL_RESEARCH_BASELINE으로 고정했습니다.

관찰된 실패

- 작업표 2건: 값과 인용은 만들었지만 마지막 JSON 대괄호를 한 번 더 닫아 MALFORMED_JSON
- 안전보고서 1건: 자유메모 지시는 실행하지 않았으나 observation ID의 인용 행이 밀려 CITATION_VALUE_MISMATCH
- 모든 실패는 화면 표시 전에 Fallback되어 여섯 run 전체 unsafeDisplayCount는 0

A.X 기술 질문

주제	질문
공식 structured output	A.X-4.0-Light 로컬 추론에서 JSON Schema-grammar-constrained decoding 또는 공식 structured-output 경로가 있는가?
generation 설정	긴 JSON의 마지막 배열 중복 닫힘을 줄이는 chat template, EOS, stopping criteria, decoding 권장값은 무엇인가?
citation 구조	여러 field가 같은 표 행을 인용할 때 flat facts보다 span table-source map 구조가 적절한가?
평가 지표	strict exact-match 외 구조 정확도·인용 충실도·지시 격리·안전 Fallback을 어떤 지표로 분리해야 하는가?
후속 학습	SFT/LoRA 전에 필요한 최소 표본 규모, 실제 문서 혼합 비율, 라이선스·재배포 경계는 무엇인가?

07 SKT 멘토에게 꼭 묻고 싶은 질문

답변이 바로 다음 개발 우선순위로 이어지도록 원하는 결론을 함께 적었습니다.

1	AI 책임 분리가 맞는가? 결정론 코어가 점수·추천을 소유하고 AI는 파싱·설명만 담당하는 구조가 기업 고객·대회 심사에서 충분한 AI 제품으로 보이는지 확인하고 싶습니다.	유지 / AI 역할 확대 영역
2	첫 구매자는 누구인가? 본사 안전팀, 허브 운영관리자, 배송사 IT, 보험·관제 파트너 중 누가 실제 예산과 도입 권한을 가질 가능성이 높은지 궁금합니다.	우선 구매자 1순위
3	첫 유료 파일럿의 최소 범위는? 1개 허브·기사 20~50명·4~8주 Shadow mode가 적절한지, 더 작거나 커야 하는지 조언이 필요합니다.	인원·기간·운영 방식
4	실제 데이터의 최소 세트는? 근무표·남은 배송·계획 ETA·날씨·경로 위험만으로 시작할지, GPS·차량 텔레매틱스까지 필수인지 판단이 필요합니다.	P0 데이터 계약
5	GPS는 어느 정밀도·주기가 적절한가? 운영 가치와 기사 프라이버시를 함께 만족하는 표시 단위, 갱신 주기, 보존기간을 묻고 싶습니다.	위치 수집 원칙
6	사고 라벨 없이 어떻게 검증할까? 사고감소를 주장하지 않고도 shadow decision의 품질을 입증할 KPI와 go/no-go 기준이 필요합니다.	파일럿 성공지표
7	TMS 연동은 어디부터 시작할까? 읽기 전용 snapshot 수집 후 승인 결과 CSV 반환으로 시작할지, 초기부터 쓰기 API와 롤백을 구축할지 조언이 필요합니다.	연동 1단계 범위
8	8월 14일 발표에서 무엇을 빼야 할까? 문서 AI·지도·PWA·Risk Transfer Guard 중 3분 안에 무엇을 핵심 장면으로 남길지 선택하고 싶습니다.	히어로 장면 1~2개

가장 중요한 3개

시간이 부족하면 ① AI 책임 분리의 타당성, ② 첫 유료 파일럿의 범위와 성공지표, ③ 8월 14일 발표의 히어로 장면만큼은 반드시 답을 받습니다.

08 멘토링에서 결정받고 싶은 항목

답을 받은 뒤 문서·구현·평가에 반영할 수 있도록 선택지를 정리했습니다.

결정 주제	선택지	현재 제안
제품 포지셔닝	안전운영 코파일럿 / 배차 최적화 / 문서 AI	안전운영 코파일럿 유지
AI 핵심 역할	문서 추출 / 설명 / 시나리오 생성 / 추천	추출+설명, 추천 권한 없음
첫 고객	본사 안전팀 / 허브 운영 / IT·관계	멘토 의견 필요
파일럿 모드	읽기 전용 Shadow / 제한 쓰기 / 자동 적용	읽기 전용 Shadow
파일럿 규모	10명 / 20~50명 / 100명+	20~50명 제안
핵심 KPI	사고율 / breach 예방 / 승인속도 / 수용성	breach·위험전가·수용성
위치정보	미사용 / 저정밀 / 정밀 실시간	저정밀·근무시간 제한
발표 히어로	지도 / 문서 / 개입·승인 페루프	Risk Transfer Guard 페루프

8월 14일까지 권장 일정

날짜	단계	완료 기준
7/29	멘토링	제품·AI·파일럿·발표 우선순위 결정
7/30~8/2	반영	필수 문구·설명·증거 보강, 디자인 확정, 신규 기능 최소화
8/3~8/6	독립 검토	관리자 3명·기사 5명 결과 취합
8/7~8/9	수정·재검토	오인 발생 시 화면 수정 후 새 배포 기준 전체 재실행
8/10	기능 동결	P0 기능·데이터·AI 경계 확정
8/11~8/13	릴리스	재배포, 전체 Gate, 제출 ZIP, 발표 PC clean-start, 3분 리허설
8/14	최종 발표	합성 경계와 미완료 범위를 숨기지 않고 페루프 시연

개발 우선순위 원칙

멘토링 결과가 있더라도 Safety Budget·Risk Transfer Guard·기사 거절권·사람 승인 권한을 약화하는 변경은 하지 않습니다. 신규 기능보다 독립 검토·릴리스 정합성·발표 재현성을 우선합니다.

09 세션 진행 순서와 메모

15~20분 기준으로 사용하고, 아래 빈칸에는 멘토의 결론을 적습니다.

시간	주제	말할 핵심
0~2분	문제와 제품	미래 안전한계 초과 → 개입 → 동의승인 → 계획 갱신
2~5분	현재 데모	관리자 지원 큐·Risk Transfer Guard·기사 응답·경로 적용
5~8분	검증	299/299, 33/33, 240명, unsafe 추천 0, D1·Upstage·Kakao
8~12분	A.X 실험	frozen 17/20, exact citation 실패, 제품 미통합 이유
12~18분	질문	AI 역할·파일럿 데이터·KPI·구매자·발표 우선순위
18~20분	결정 확인	오늘 합의한 3개와 다음 실행일을 복창

마지막에 반드시 확인할 문장

- “SafeRoute의 제품 포지셔닝은 _____으로 유지/수정한다.”
- “A.X의 다음 실험은 _____을 먼저 검증하고, 제품 통합 조건은 _____이다.”
- “첫 파일럿은 _____명, _____주, _____모드로 설계한다.”
- “8월 14일 발표의 핵심 장면은 _____이며, _____은 제외한다.”

멘토 메모

부록 현재 한계와 근거 파일

완료하지 않은 것을 정확히 말하는 것이 이번 멘토링의 신뢰도를 높입니다.

영역	현재 한계	처리 원칙
독립 검토	관리자 0/3, 기사 0/5	현재 공식 Goal blocker
실제 데이터	기사-고객 PII, 정밀 GPS, 생체, 비공개 TMS 없음	합성 운영 서비스
인증-권한	실제 계정-SSO-테넌트-MFA 없음	데모 역할 분리
알림	고객안내는 PREVIEW_ONLY 미발송 초안	실제 전송 없음
현장효과	사고감소-생산성-실사용성 미검증	Shadow pilot 필요
A.X 문서추출	PARTIAL_RESEARCH_BASELINE	제품 런타임 미통합
배포 정합성	최신 로컬 UI와 마지막 smoke commit 불일치	재배포-재감사 필요

재현 근거

구분	경로
공식 목표	docs/service-goal-2026-08-14.md
제품 명세	docs/product-spec.md
아키텍처	docs/architecture.md
안전 모델	docs/safety-model.md
개입 정책	docs/intervention-policy.md
개인정보-AI	docs/privacy-and-ai-policy.md
평가 계획	docs/evals.md
A.X 멘토링 브리프	docs/a100-operations-document-mentor-brief.md
최신 서비스 판정	artifacts/evals/service-goal-readiness-latest.json
공개 배포 smoke	artifacts/evals/operations-deployed-smoke-latest.json

멘토링 종료 후 바로 할 일

오늘 받은 결론을 decisions.md와 관련 승인 문서에 기록하고, 영향 범위를 정한 뒤 구현-평가를 진행합니다. 디자인이 확정되면 최신 커밋을 공개 배포하고 전체 자동 Gate와 독립 사람 검토를 같은 release identity에서 다시 실행합니다.

작성 기준: 2026-07-29 KST
서비스 Goal 증거: 2026-07-28T03:29:05.896Z
공개 배포 smoke: 2026-07-28T05:24:55.292Z
데이터 모드: SYNTHETIC